INSTITUTO FEDERAL
São Paulo
Campus Boituva

OPOSIÇÃO À NUVEM PÚBLICA IRRESTRITA E AO FINOPS REATIVO

Uma análise crítica de custos, dependência tecnológica e alternativas de infraestrutura.

Tópicos Avançados em Sistemas de Informação
Bruna Serra, Vinicius Araújo e Victoria Benfica

SUMÁRIO

01 O Paradoxo econômico da nuvem

02 Custos ocultos e armadilhas tarifárias

03 Aprisionamento tecnológico

04 Repatriação moderna e a metodologia framework diel

05 Matriz de decisão arquitetural para alocação de workloads

06 Referências Bibliográficas

07 Conclusão

O PARADOXO ECONÔMICO DA NUVEM

A computação em nuvem surgiu com a promessa de reduzir investimentos iniciais (CapEx) e oferecer custos operacionais flexíveis (OpEx). Porém, em empresas de grande escala, seus custos podem representar 75% a 81% do COR/COGS, gerando um impacto estimado entre US$ 100 bilhões e US$ 500 bilhões no valor de mercado das 50 maiores empresas públicas de software analisadas (Wang & Casado, 2021).



O PARADOXO ECONÔMICO DA NUVEM

"Se você está operando em escala, o custo da nuvem pode, no mínimo, dobrar a sua fatura de infraestrutura... Você é louco se não começar na nuvem; você é louco se permanecer nela."

— Sarah Wang & Martin Casado (Andreessen Horowitz, 2021)



O PARADOXO ECONÔMICO DA NUVEM

Dropbox

O FinOps (Operações Financeiras) controla gastos com a nuvem, podendo reduzir custos em 20% a 30%, com até 72% de desconto em instâncias reservadas e de 40% a 60% com rightsizing. No entanto, essas práticas não resolvem tarifas elevadas dos provedores. Um exemplo é o Dropbox, que migrou 600 PB de dados da AWS para sua própria infraestrutura, economizando US$ 75 milhões em dois anos e aumentando sua margem bruta de 33% para 67%.





O PARADOXO ECONÔMICO DA NUVEM

"Quando existe um segmento de mercado puramente para ajudar clientes a entender suas faturas da AWS, algo estrutural deu errado no modelo de precificação... O 'Cloud First' morreu: o que o substituiu foi a alocação correta da carga de trabalho no lugar correto."

— Russell Smith, Diretor de Produtos Private Cloud na Civo (2026)

Dropbox



CUSTOS OCULTOS, ARMADILHAS TARIFÁRIAS E ANÁLISE DE BREAK-EVEN

As análises de TCO frequentemente desconsideram custos adicionais da nuvem, como tarifas de saída de dados (egress), transferências entre zonas e armazenamento crescente. Segundo a análise detalhada de Yang (2026) da Ertas AI, enquanto o custo da hora-GPU em nuvem pública (ex: AWS p5 com H100 a US$ 3,90/h ou A100 a US$ 2,80/h) parece atraente no início, a infraestrutura acumulada de armazenamento (50TB a US$ 27.600/ano), egress (US$ 0,09/GB) e serviços auxiliares eleva o TCO de 3 anos de um único servidor 8xA100 na nuvem para cerca de US$ 543.312 a US$ 680.000



CUSTOS OCULTOS, ARMADILHAS TARIFÁRIAS E ANÁLISE DE BREAK-EVEN

Categoria de Custo	Nuvem Pública (8xA100 Reservada)	Infraestrutura Própria / On-Premise (8xA100)
Custo Ano 1	US$ 181.104 (Serviços + Egress + Storage)	US$ 360.000 (Hardware amortizado + Energia/Cooling)
Custo Ano 2	US$ 181.104 (Assumindo sem crescimento)	US$ 108.000 (Manutenção + Energia + Equipe)
Custo Ano 3	US$ 181.104 (Com acúmulo de dados: >US$ 300k)	US$ 108.000 (Operação contínua pré-paga)
TCO Acumulado (3 Anos)	**US$ 543.312 – US$ 680.000**	**US$ 576.000** **(Economia de 50% a 70% pós-break-even)**

Análise de Ponto de Equilíbrio (Break-Even): Para cargas de trabalho com utilização contínua superior a 50% (como pipelines de produção de IA, inferência 24/7 ou bancos de dados relacionais principais), o hardware próprio se paga em um período de 7 a 18 meses (Yang, 2026; Smith, 2026).

Após o investimento inicial (CapEx), os custos recorrentes representam uma fração do valor cobrado pelos hiperescaladores, gerando uma economia sustentável de 50% a 70% em 3 anos.

APRISIONAMENTO TECNOLÓGICO (VENDOR LOCK-IN) E A ILUSÃO DA SOBERANIA

A oposição à nuvem pública também se fundamenta na perda de controle arquitetural e estratégico. O estudo seminal de Opara-Martins, Sahandi & Tian (2016), com 114 profissionais de TI no Reino Unido, revelou que a ausência de padronização em APIs e a incompatibilidade de formatos proprietários de dados constituem as principais barreiras para a mobilidade entre fornecedores, gerando um aprisionamento (*vendor lock-in*) severo e custos proibitivos de migração



"Em junho de 2025, a Microsoft testemunhou perante o Senado Francês que não poderia garantir que os dados da União Europeia estivessem fora do alcance do US CLOUD Act... Soberania por acordo contratual é suplantada pela lei extraterritorial; a verdadeira soberania vem da arquitetura."
— Relatório Civo / Depoimento do Senado Francês (Russell Smith, 2026)

APRISIONAMENTO TECNOLÓGICO (VENDOR LOCK-IN) E A ILUSÃO DA SOBERANIA

A alegação de muitos hiperescaladores de oferecer 'nuvens soberanas' mediante acordos jurídicos de residência de dados é desconstruída por Smith (2026): acordos contratuais não sobrepõem leis federais de jurisdição extraterritorial dos EUA. Para contornar o lock-in, Opara-Martins et al. (2016) recomendam a adoção de padrões abertos neutros, tais como as especificações TOSCA (Topology and Orchestration Specification for Cloud Applications) e CAMP (Cloud Application Management for Platforms) da OASIS, garantindo a orquestração agnóstica de infraestrutura.



REPATRIAÇÃO MODERNA E A METODOLOGIA FRAMEWORK DIEL

O grande equívoco sobre a repatriação é supor que ela significa o retorno à TI antiga e engessada dos anos 2000. Conforme detalhado por Smith (2026) e Jindal et al. (2026), a repatriação moderna mantém integralmente a maturidade cloud-native: contêineres Docker/Kubernetes, Infraestrutura como Código (Terraform), microsserviços e pipelines de CI/CD. O que muda é apenas a camada física subjacente, migrando para hardware dedicado operado sob modelos ZeroOps ou nuvens privadas agnósticas



REPATRIAÇÃO MODERNA E A METODOLOGIA FRAMEWORK DIEL

Para operacionalizar essa transição de forma automatizada sem manter dois códigos-fonte paralelos, Jindal et al. (2026) desenvolveram o Framework Diel (aplicado com sucesso no Tursio AI), estruturado em três estratégias fundamentais:

- **Simulate (Simulação Local):**

Substituição de serviços gerenciados proprietários por emuladores e stubs locais (ex: simulação do AWS S3 via Boto3 stub/MinIO, compute AWS Elastic Beanstalk via Docker/Kubernetes e cron jobs simulando AWS MWAA/Airflow)

- **Replicate (Replicação Aberta):**

Utilização de equivalentes de código aberto para banco de dados e logs (ex: AWS RDS PostgreSQL substituído por PostgreSQL nativo e AWS CloudWatch substituído por logs em formato Protobuf comprimido).

REPATRIAÇÃO MODERNA E A METODOLOGIA FRAMEWORK DIEL

- **Delegate (Delegação Segura):**

Delegação de serviços complexos ou sensíveis diretamente para a assinatura de nuvem do cliente (ex: SSO autenticado via Microsoft Entra ID e serviços de IA delegados para o Azure OpenAI do cliente via endpoints privados).

> *"Com o Diel, conseguimos manter as versões de nuvem e locais do Tursio AI perfeitamente sincronizadas, lançando uma nova versão estável a cada três semanas... Foi a implementação de IA mais rápida de que já ouvi falar."*
> *— Alekh Jindal et al. (Tursio AI, 2026) / Depoimento de VP de Instituição Financeira*

MATRIZ DE DECISÃO ARQUITETURAL PARA ALOCAÇÃO DE WORKLOADS

A decisão de repatriação não deve ser uma rejeição dogmática da nuvem pública, mas sim uma alocação pragmática baseada no perfil da carga de trabalho (Smith, 2026; Yang, 2026). A matriz a seguir orienta a decisão arquitetural com base no próximo slide:

Perfil de Carga de Trabalho	Ambiente Recomendado	Justificativa Econômica e Técnica	Fonte de Referência
Cargas Sustentadas (>50% utilização)	Nuvem Privada / On-Premise	Economia de 50% a 70% no TCO de 3 anos; eliminação do custo por hora acumulado.	Yang (2026) / Smith (2026)
Treinamento de IA e Inferência 24/7	Infraestrutura Dedicada / GPU Local	Eliminação de cobranças maciças de tráfego (egress) e taxas de token de APIs gerenciadas.	Yang (2026) / Jindal (2026)
Dados Regulados e Sensíveis	Nuvem Privada Soberana	Garantia real contra leis extraterritoriais (US CLOUD Act); soberania por arquitetura.	Smith (2026) / Opara-Martins (2016)
Cargas Intermitentes / Bursty (<30%)	Nuvem Pública (Elasticidade)	Paga-se apenas pelo uso esporádico; evita capacidade ociosa em hardware dedicado.	Smith (2026) / Thumala (2024)
Protótipos e Experimentos Rápidos	Nuvem Pública (Pay-as-you-go)	Velocidade de implantação sem compromisso financeiro de longo prazo.	Wang & Casado (2021)

REFERÊNCIAS BIBLIOGRÁFICAS (FONTES GROUNDED)

Jindal, A., Pandey, J., Pavlopoulou, C., PR, R., Prakash, S., Qiao, S., Tripathi, S., & Zhang, W. (2026). Reverse Migration of Cloud Applications to On-premises. Tursio AI Research Paper (ArXiv:2608.11640v2).

Opara-Martins, J., Sahandi, R., & Tian, F. (2016). Critical analysis of vendor lock-in and its impact on cloud computing migration: a business perspective. Journal of Cloud Computing: Advances, Systems and Applications, 5(4), 1-21.

Smith, R. (2026). Cloud Repatriation Strategies: From Public Dependency to Hybrid Flexibility. Civo Enterprise Infrastructure Whitepaper.

Thumala, S. R., & Pillai, B. S. (2024). Cloud Cost Optimization Methodologies for Cloud Migrations. International Journal of Intelligent Systems and Applications in Engineering (IJISAE), 12(21s), 4797–4809.

Wang, S., & Casado, M. (2021). The Cost of Cloud, a Trillion Dollar Paradox. Andreessen Horowitz (a16z) Enterprise Insights Report.

Yang, E. X. (2026). Cloud vs On-Premise AI: Complete TCO Analysis for Enterprise in 2026. Ertas AI Technical Report

OBRIGADO!